

Отчет по экспериментам: анализ тональности

Данные и препроцесс:

- Исходный train 232 366 строк, test 58 092, классы почти сбалансированы.
- Препроцесс: очистка URL/контактов/HTML/эмодзи/брань, маркеры оценок (10- и 5-балльные, звезды), капс/EN; укорочение до ~900 символов по “сигнальным” предложениям; даунсемпл до 40k на источник; стратифицированный split 90/10; мягкие аугментации; доменные префиксы [SRC_*].
- Готовые выборки: train_super 106 311, val_super 11 771, test_super 58 092.

Модели и результаты (macro-F1 на val_super):

- blanchefort/rubert-base-cased-sentiment-rusentiment: 0.7561
- DeepPavlov/rubert-base-cased-conversational: 0.7347
- ai-forever/RuRoBERTa-base (дообученная): 0.7338
- cointegrated/rubert-tiny2 (дообученная): 0.6871
- Ансамбль BERT + TF-IDF+LR: 0.6642
- TF-IDF + Logistic Regression (Optuna): 0.6222
- TF-IDF + SVD + HistGradientBoosting: 0.6101
- TF-IDF + LinearSVC: 0.5997

Почему выбрали blanchefort/rubert-base-cased-sentiment-rusentiment:

- Лучшее macro-F1 (0.7561) среди протестированных моделей.
- Модель уже дообучена на русскоязычных отзывных корпусах (Rusentiment), совпадает с задачей.
- Быстрая интеграция: веса/токенизатор доступны, совместимы с текущим препроцессом [SRC_*].
- Стабильность на разных источниках: доменные токены сохраняют контекст, качество не падает на смешанных src.

Ссылки (из обзора “Открытые модели для анализа тональности”):

- <https://habr.com/ru/articles/555064/>
- <https://fxis.ai/edu/harnessing-sbert-large-for-sentiment-analysis-on-the-russian-news-dataset/>
- <https://huggingface.co/sismetanin/rubert-ru-sentiment-rusentiment>
- <https://huggingface.co/sismetanin/sbert-ru-sentiment-rusentiment>
- <https://huggingface.co/DeepPavlov/rubert-base-cased-conversational>